

1. Significant earthquakes since 2150 B.C.

1.1 在 Significant Earthquake Database 中下载 earthquakes-2025-10-29_21-06-00_+0800.tsv, 使用 `pandas.read_csv` 读取文件, 然后根据题目要求, 按国家分组求和并排序, 最后打印死亡人数前十名的国家及总数 (先做了一个 Nan 的填充, 防止出错, 将 Nan 值填充为 0)。

Result:

```
deaths_by_country = Sig_Eqs.fillna({'Total Deaths': 0})
top_10_deaths = deaths_by_country.groupby('Country')['Total Deaths'].sum().sort_values(ascending=False).head(10)

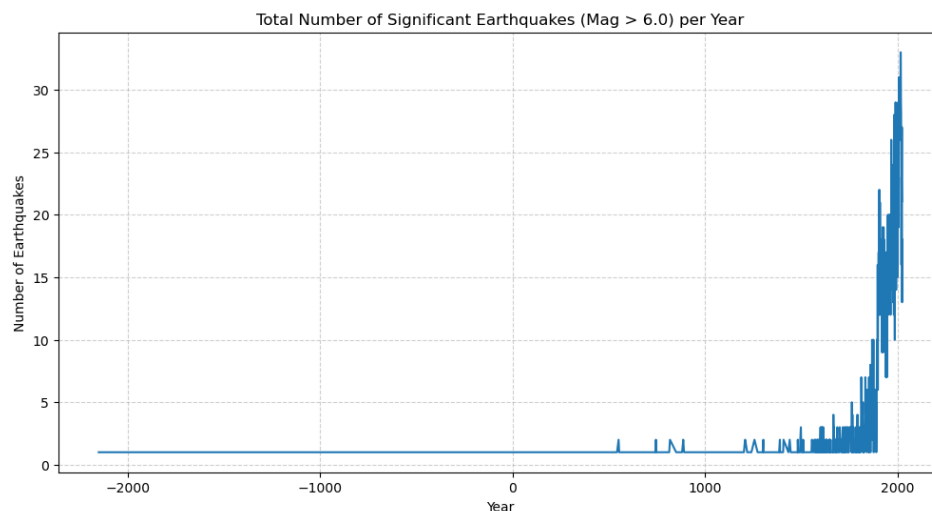
print(top_10_deaths)
```

Country	Total Deaths
CHINA	2106524.0
TURKEY	1008863.0
IRAN	761654.0
SYRIA	487726.0
ITALY	423280.0
HAITI	323782.0
JAPAN	319443.0
AZERBAIJAN	319251.0
INDONESIA	282838.0
ARMENIA	189000.0

Name: Total Deaths, dtype: float64

1.2 检查 'Mag' (震级) 和 'Year' (年份) 两列, 删除有 Nan 的数据。筛选大于 6 级地震的数据, 存储在 `mag_gt_6` 变量中, 再进行分组并计数。

Result:



由图可得: 记录到的地震数量呈明显上升趋势, 尤其是在近一百年内。

但这并不代表地震发生的实际频率增加了, 可能存在以下情况:

监测技术: 全球地震监测台站的建立和技术的进步, 使得我们能检测到更多

地震。

记录保存：历史记录不完整，越久远的地震（尤其是发生在中等强度或偏远地区的）越不容易被记录下来。

1.3 定义函数 CountEq_LargestEq：接受两个输入参数：df (完整的地震数据表) 和 country_name (国家名)，按题目要求实现代码：找出这个国家所有（带震级的）地，会计算这些地震的总次数 (total_count)，并找出震级最大 (idxmax()) 的那一行。

通过一个循环，遍历这 tsv 文件中的每一个国家，并对每个国家都调用一次 CountEq_LargestEq 函数。将函数返回的结果（国家名、总次数、最大地震日期）收集到一个 results 列表中。循环结束后，将这个列表转换为一个新的 pandas 数据表 (results_df)，并立即按照 'TotalEarthquakes'（地震总次数）这一列进行降序排序。

Result:

Country TotalEarthquakes \			LargestEarthquakeYear	
14	CHINA	592	14	1668.0
33	JAPAN	361	33	2011.0
70	INDONESIA	340	70	2004.0
7	IRAN	263	7	856.0
54	USA	229	54	1964.0
9	TURKEY	224	9	1939.0
3	GREECE	181	3	365.0
50	PERU	157	50	1716.0
58	CHILE	148	58	1960.0
15	RUSSIA	148	15	1952.0
51	MEXICO	144	51	1787.0
68	PHILIPPINES	142	68	1897.0
5	ITALY	105	5	1915.0
88	PAPUA NEW GUINEA	99	88	1919.0
74	TAIWAN	98	74	1920.0
8	INDIA	86	8	1950.0
64	COLOMBIA	68	64	1826.0
98	NEW ZEALAND	66	98	1826.0
109	SOLOMON ISLANDS	62	109	1977.0
22	AFGHANISTAN	62	22	1909.0
61	ECUADOR	58	61	1906.0
104	VANUATU	57	104	1913.0
20	PAKISTAN	44	20	1945.0
45	ALGERIA	39	45	1980.0
63	GUATEMALA	37	63	1942.0
16	ALBANIA	35	16	1893.0
53	VENEZUELA	30	53	1530.0
66	COSTA RICA	29	66	1950.0
49	MYANMAR (BURMA)	29	49	1912.0
113	TAJIKISTAN	28	113	1907.0
73	NICARAGUA	28	73	1898.0
80	ARGENTINA	28	80	1894.0
105	NEW CALEDONIA	28	105	1875.0
65	EL SALVADOR	25	65	1776.0
103	AUSTRALIA	24	103	1989.0
83	USA TERRITORY	23	83	1902.0
111	KERMADEC ISLANDS (NEW ZEALAND)	23	111	1986.0
102	TONGA	21		
21	SOUTH KOREA	21		
69	PANAMA	20		
41	NEPAL	19		

2.Wind speed in Shenzhen from 2010 to 2020

第一步是将 WND 列拆分为独立的字段：风向、风向质量、风类型、风速和风速质量。

随后，应用了以下过滤步骤：

1. 质量码检查： 代码同时检查“风向质量码”（WND 列的第 2 个值）和“风速质量码”（第 5 个值）。一条记录只有在这两个质量码同时为可接受的代码（即 '0', '1', '4', '5', 或 '9' 之一）时才会被保留。任何一个字段的质量码如果为“可疑” ('2', '6') 或“错误” ('3', '7')，该整条记录都将被丢弃。


2. 风类型码检查： 代码包含了一个 OR (或) 条件，用于处理指南中提到的特殊静风情况。如果一条记录的“风类型码”为 '9' 且其“风速”为 0 (来自 "0000")，那么即使它的质量码不符合标准（例如，风向质量码可能是 '9'），这条记录也会被视为有效的静风记录并保留下来。

3. 风向合理性检查： 此步骤已包含在步骤 1 的质量码检查中。根据指南，如果风类型为 'V' (Variable)，风向为 999 是合理的，此时其风向质量码应为 '1' 或 '5' 等有效代码，该记录会被保留。如果风类型不是 'V' 但风向为 999，这将被视为一个错误，其质量码（很可能是 '3' 或 '7'）会导致该行在步骤 1 中被丢弃。

4. 风速缺失值检查： 代码会检查原始风速值。所有风速为 9999（指南中定义的缺失标识）的记录，都会在转换为数字时被视为空值 (NaN)，并从分析中排除。

5. 数据转换和范围验证： 最后，原始风速文本（如 "0020"）被转换为数字。此转换过程（以及对 9999 的排除）确保了数据落在 0000-0900 的有效范围内。根据指南的缩放因子要求，所有有效的风速值都会除以 10，以得到米/秒 (m/s) 为单位的最终风速，用于后续的绘图和趋势计算。

Result:



尽管风速有强烈的季节性波动（每年冬高夏低），但在 2010 年至 2020 年期间，深圳宝安机场的月平均风速显示出一个显著的长期上升趋势。

3.Explore a data set

3.1 本题使用的数据是 Cooley 等基于 ICESat-2 激光测高任务得到的全球湖泊水位数据（2018.10-2022.07），使用 read_csv 和 shape 读取并展示该 CSV 数据的行列数和各字段名称。

行数 (Rows): 227386
列数 (Columns): 27

id	Latitude	Longitude	Area	Type	Oct2018	Nov2018	\	
0	77.912613	-23.634773	0.666206	Natural	NaN	NaN		
1	77.892250	-23.822008	0.108693	Natural	NaN	928.545349		
2	77.868866	-20.779461	0.315888	Natural	NaN	NaN		
3	77.843330	-110.950310	0.598154	Natural	NaN	-3.412109		
4	77.831947	-20.891270	0.355333	Natural	NaN	NaN		
	Dec2018	Jan2019	Feb2019	Mar2019	Apr2019	May2019	\	
0	775.671814	NaN	NaN	NaN	NaN	NaN		
1	NaN	928.693787	NaN	NaN	NaN	928.926147		
2	NaN	NaN	NaN	NaN	90.351400	NaN		
3	-3.328942	NaN	-3.199217	NaN	NaN	-3.154937		
4	NaN	NaN	NaN	NaN	171.377846	171.282623		
	Jun2019	Jul2019	Aug2019	Sep2019	Oct2019	Nov2019	Dec2019	\
0	NaN	NaN	NaN	NaN	NaN	772.795502	NaN	
1	NaN	NaN	NaN	NaN	NaN	NaN	NaN	
2	NaN	89.984301	NaN	NaN	89.826809	NaN	NaN	
3	-3.167234	NaN	NaN	-3.637697	NaN	NaN	-3.448276	
4	NaN	170.826790	NaN	NaN	171.002904	170.972336	NaN	
	Jan2020	Feb2020	Mar2020	Apr2020	May2020	Jun2020	Jul2020	
0	NaN	NaN	NaN	NaN	NaN	NaN	NaN	
1	NaN	927.205017	NaN	NaN	NaN	NaN	NaN	
2	NaN	NaN	NaN	90.550261	NaN	NaN	NaN	
3	NaN	-3.323550	-3.277608	NaN	NaN	-3.353647	NaN	
4	NaN	NaN	NaN	NaN	NaN	NaN	NaN	

由于原数据包含全球数十万个湖泊这里考虑展示超大湖泊，筛选出面积字段大于 10000 的数据（共筛选出 15 个湖泊）。

```
#挑出面积大于10000的数据
df_lakes = df[df['Area'] > 10000]
print(len(df_lakes))
print(df_lakes)
```

转为数字格式使用 `isnull` 读取缺失值，为保证后面序列图较为完整，考虑采用简单的插值进行填充（使用简单的线性插值，边缘的直接使用最近月份填充）

Result:

```
转换为数字格式后，所有月份列中总共有 25 个 NaN 值。
线性插值完成。
边缘填充完成。
插值和边缘填充后，所有月份列中剩余 0 个 NaN 值。

--- 3.1 (宽格式) 插值完成 ---
插值后数据预览 (df_cleaned):
```

	id	Latitude	Longitude	Area	Type	Oct2018 \
95540	95541	66.170349	-123.098793	22622.509073	Natural	142.182180
142792	142793	61.623337	-114.189430	26039.404469	Natural	126.583547
149420	149421	60.752140	31.949997	17116.098144	Reservoir	20.877350
191046	191047	53.086105	-98.453865	24827.936811	Reservoir	184.391208
193605	193606	52.548405	106.370277	31951.020835	Reservoir	421.951141

		Nov2018	Dec2018	Jan2019	Feb2019	Mar2019 \
95540	143.606663	142.518844	143.242034	143.835225	143.567022	
142792	127.078623	127.541004	127.211344	127.163485	126.985538	
149420	19.895657	19.942883	20.431718	21.033176	19.634016	
191046	184.288714	184.278557	185.391982	187.286412	186.097685	
193605	418.897403	419.534525	419.740347	417.782043	417.859833	

		Apr2019	May2019	Jun2019	Jul2019	Aug2019 \
95540	143.540918	143.718724	142.948381	143.356049	143.763718	
142792	126.825382	126.817694	127.043706	126.247117	127.421238	
149420	21.487126	20.627504	20.313654	20.277207	20.247953	
191046	184.908958	189.195905	185.168013	186.473242	187.778471	
193605	420.148443	421.285627	417.424483	420.437762	423.451042	

		Sep2019	Oct2019	Nov2019	Dec2019	Jan2020 \
95540	143.518135	142.839623	142.367170	143.590946	143.734313	
142792	127.344134	127.108449	127.883572	128.722741	127.283182	
149420	23.034639	20.076752	20.009856	19.534496	21.897986	
191046	183.776223	184.775945	184.567415	185.127782	185.498128	
193605	419.351915	420.813239	419.347108	418.628769	420.761242	

		Feb2020	Mar2020	Apr2020	May2020	Jun2020	Jul2020
95540	143.383112	143.370858	144.823421	143.574838	143.143247	143.478931	
142792	127.117013	127.262662	127.772008	128.684613	127.195734	127.195734	
149420	21.590687	20.121696	22.742567	21.146817	22.509172	20.937564	
191046	185.436180	185.711409	186.486258	187.740797	184.656055	186.586935	
193605	417.469236	417.501212	418.777261	418.502194	418.323616	421.978538	

3.2 该数据与多维数据不同，直接将各月水位数据作为列，所以除去前五列信息外后面为时间及其对应的水位。读取后面的列名转化为时间格式，挑选了前五个湖泊绘制它们的水位时间序列图。

Result:



